

Pokretanje projekta

Zahtevi

- Python 3.12
- Windows, Linux ili macOS, testirano na CPU, CPUExecutionProvider
- Internet konekcija pri prvom pokretanju, MNIST dataset se automatski preuzima

1. Kloniranje repozitorijuma

```
git clone https://github.com/nemanjalj02/ONNX_kvantizacija.git  
cd ONNX_kvantizacija
```

2. Kreiranje virtuelnog okruženja, preporučeno

Direktno pokretanje `pip install -r requirements.txt` može napraviti konflikt sa sistemskim paketima, zato se preporučuje kreiranje izolovanog okruženja.

```
python -m venv venv
```

Aktivacija na Windows-u:

```
venv\Scripts\activate
```

Aktivacija na Linux-u ili macOS-u:

```
source venv/bin/activate
```

3. Instalacija okruženja

```
pip install -r requirements.txt
```

Instalira: numpy, onnx, onnxruntime, torch, torchvision, matplotlib, scikit-learn, onnxscript.

4. Trening modela, opciono, ako lenet5_best.pth već postoji

Pokrenuti `01_training_preparation/CNN_training.ipynb`, trenira LeNet5 na MNIST-u i čuva težine u `02_original_model/lenet5_best.pth`, izvozi model u `lenet5.onnx`. Pri prvom pokretanju automatski preuzima MNIST u `data/`.

Notebook je pokretan kroz Google Colab, uz korišćen T4 GPU.

5. Provera izvezenog ONNX modela

```
python 01_training_preparation/verify_export.py
```

Proverava da PyTorch i ONNX model daju iste izlaze, tri nivoa provere: strukturna provera, poređenje izlaza, provera opset-a. Očekuje lenet5.onnx i lenet5_best.pth u 02_original_model/.

6. Priprema modela za kvantizaciju, shape inference

```
python 01_training_preparation/preprocess.py
```

Ulaz: 02_original_model/lenet5.onnx, izlaz: 02_original_model/lenet5_prep.onnx.
Ovaj fajl je ulaz za sve tri varijante kvantizacije.

7. Kvantizacija, tri varijante, svaka generiše INT8 i INT16

```
python 03_quantization_variants/quantize_weights_only.py  
python 03_quantization_variants/quantize_weights_and_bias.py  
python 03_quantization_variants/quantize_static_variant.py
```

V1, samo težine.

V2, težine i bias.

V3, težine, bias i aktivacije, statička kvantizacija, sa kalibracijom na 200 uzoraka.

Rezultati se čuvaju u 04_quantized_models/.

8. Poređenje modela

```
python 05_compare_models/01_accuracy.py  
python 05_compare_models/02_size_breakdown.py  
python 05_compare_models/03_inference.py  
python 05_compare_models/check_fusion.py  
python 05_compare_models/diff_predictions.py
```

01_accuracy.py, top-1 tačnost FP32 modela i svih kvantizovanih modela.

02_size_breakdown.py, veličina modela po tenzorima.

03_inference.py, brzina inferencije, 50 zagrevajućih i 1000 mernih prolaza.

check_fusion.py, provera fuzionisanja QDQ grafa u celobrojne kernele.

diff_predictions.py, razlike u predikcijama po uzorku.

01_accuracy.py i 03_inference.py mogu primiti i putanje do modela kao argumente, na primer python 01_accuracy.py putanja1.onnx putanja2.onnx. Bez argumenata testiraju automatski FP32 model i sve fajlove iz 04_quantized_models/.

9. Grafik treninga

```
python 06_plots/plot_training.py
```

Generiše 06_plots/training_curve.png.

Redosled pokretanja, ukratko

`git clone`, `venv`, `pip install`, zatim `preprocess.py`, zatim `quantize_*.py` (V1, V2, V3), zatim skripte u `05_compare_models/`.

Napomene

- MNIST dataset, `data/MNIST/`, se ne prati u git-u, `.gitignore`, i preuzima se automatski pri prvom pozivu bilo koje skripte koja koristi `torchvision.datasets.MNIST`.
- Sve skripte koriste apsolutne putanje relativne u odnosu na koren projekta, `Path(__file__).resolve().parents[...]`, pa se mogu pokretati iz bilo kog direktorijuma.