

KVANTIZACIJA NEURONSKIH MREŽA KORIŠĆENJEM ONNX FORMATA

PRINCIPI DUBOKOG UČENJA

Profesor: dr Nikša Jakovljević
Asistent: dr Nikola Simić

Student: Nemanja Ljubičić, E9 8/2025

KVANTIZACIJA

MOTIVACIJA

- Modeli mašinskog učenja danas rešavaju složene zadatke sa visokom tačnošću, ali zato imaju veliki broj parametara i potrebu za intenzivnim računanjem.
- Problem nastaje pri postavljanju takvih modela van servera (na telefonima, ugrađenim i edge uređajima):
 - Kapacitet: model mora da stane u ograničenu memoriju uređaja i da se izvrši u razumnom vremenu.
 - Toplota: računanje u pokretnom zarezu zagreva čip, koji nema aktivno hlađenje.
 - Baterija: svaka operacija troši energiju, a ona je ograničena.

KVANTIZACIJA

ZNAČENJE

- Kvantizacija ovaj problem rešava smanjenjem broja bitova kojim se predstavlja svaki broj u mreži (težine i aktivacije: 16, 8, 4 ili 2 bita umesto 32):
 - Model zauzima višestruko manje prostora (prelazak na INT8 smanjuje težine $4\times$, na INT16 $2\times$)
 - Računanje nad celim brojevima je brže i troši manje energije od rada sa pokretnim zarezom.
 - Namenski hardver često je i projektovan za celobrojnu aritmetiku niske preciznosti.
- Kao posledica ovog postupka, javlja se greška u tačnosti. Kolika će ona biti, zavisi od toga kako se realne vrednosti preslikavaju u celobrojne. To opisuje matematička formulacija kvantizacije.

KVANTIZACIJA

MATEMATIČKA FORMULACIJA

- Kvantizacija mapira početne realne vrednosti x iz nekog opsega (r_{min} , r_{max}) na manji skup diskretnih nivoa (q_{min} , q_{max}), u vrednost y .
- Kod asimetrične kvantizacije, skala pokriva stvarni opseg parametara, a realna donja granica r_{min} preslika se u celobrojnu donju granicu q_{min} , čime se dobija:

$$y_{scale} = (r_{max} - r_{min}) / (q_{max} - q_{min})$$
$$y_{zero_point} = round(q_{min} - (r_{min} / y_{scale}))$$

- Kod simetrične kvantizacije opseg prvo simetriše oko nule, pa se umesto stvarnog opsega uzima dvostruka vrednost veće apsolutne granice

$$y_{scale} = 2 \cdot \max(|r_{min}|, |r_{max}|) / (q_{max} - q_{min})$$
$$y_{zero_point} = 0$$


KVANTIZACIJA

MATEMATIČKA FORMULACIJA

- Ta dva parametra, y_scale i y_zero_point , potpuno definišu preslikavanje, koje se onda zapisuje:

$$y = \text{satuate}(\text{round}(x / y_scale) + y_zero_point)$$

- Rezultat deljenja x / y_scale zaokružuje se na najbliži ceo broj, a vrednosti tačno na polovini (npr. 2.5) zaokružuju se na najbliži paran broj (*round to nearest even*).



ONNX

MOTIVACIJA

- Da bi se opisano preslikavanje zaista primenilo na model, ono mora negde da bude zapisano i izvršeno.
- Za to se koristi ONNX (Open Neural Network Exchange), otvoren standard za predstavljanje modela mašinskog učenja, nezavisan od okvira u kom je model napravljen.
- Odnosno, model se može trenirati u PyTorch-u, izvesti u ONNX, pa dalje kvantizovati i pokretati kroz ONNX Runtime.
- Ovo je omogućeno time što se model zapisuje kao računski graf, koji u potpunosti opisuje šta model radi.
- Takođe, ONNX definiše kvantizaciju kroz taj isti graf i omogućava eksperimentisanje sa različitim šemama.
- ONNX Runtime pokreće graf efikasno i na različitom hardveru.

CNN


DATASET I ARHITEKTURA

- Model na kom će biti sproveden postupak kvantizacije u ONNX formatu je konvoluciona neuronska mreža.
- Arhitektura: LeNet-5 (moderna varijanta)
 - Izvorno predložena za prepoznavanje rukom pisanih cifara
 - Moderni izbor slojeva: ReLU aktivacije i max-pooling
- Dataset: MNIST
 - 70.000 slika rukom pisanih cifara (60k trening, 10k test)
 - Format: 28×28 piksela, sivi tonovi, 10 klasa (cifre 0–9)
 - Standardan referentni skup za klasifikaciju slika
- Okvir: PyTorch
 - Model se trenira u PyTorch-u (FP32), zatim izvozi u ONNX
 - To daje ranije spomenutu grafovsku reprezentaciju

GRAF

- Model CNN se čuva kao računski graf. Sadrži sve što je neophodno za kasnije rekreiranje mreže: Operacije koje se izvode u mreži, tok podataka, težine i biasi su sadržani u njemu.
- To je prenosivi opis toka izračunavanja.
- Sastoji se od:
 - Ulaza: Tip i oblik
 - Čvorova: svaki čvor je jedna operacija (npr.konvolucija)
 - Atributa: fiksni parametri jedne operacije (veličina kernela, korak, ...)
 - Inicijalizatora: konstantne vrednosti ugrađene u graf, naučene težine i biasi
 - Grana: između čvorova, opisuju tok podataka
 - Izlaza: tip i oblik
- Ovaj graf je:
 - Acikličan: nema petlji. Ne postoji put kojim se praćenjem usmerenih grana može vratiti u isti čvor. Tamo gde su potrebne petlje u izračunavanju, sadržane su u jednom čvoru.
 - Topološki uređen: ispred svakog čvora su svi čvorovi koji su potrebni za njegovo izračunavanje.

GRAF



PRAVILNOST IZVOZA

- Pre daljega rada sa modelom, vrši se njegova provera po tri kriterijuma.
 - Modul `onnx.checker` je skup alata za proveru ONNX izvoza, tj. da li je model ispravan po ONNX specifikaciji. Više funkcija, koje proveravaju različite nivoe modela (ceo model, graf, čvor, attribute, tenzore, tipove).
 - Uključivanjem parametra `full_check`, pored pomenute validacije radi se i provera oblika tenzora kroz graf.
 - Propuštanje istog ulaza na oba modela, tj. kroz model dobijen u PyTorch (referenca) i kroz ONNX model.
 - Porede se izlazi pod istim uslovima (inference režim), uz dozvoljenu toleranciju.
 - Verzija skupa operatora koju model koristi se menja kroz vreme.
 - Dve strane moraju da se slože: opset kojim je model izvezen i opset koji Runtime koristi.
 - Ako runtime ne podržava traženi opset, model se ne pokreće.
-
- Strukturna provera fajla
- Provera izlaza
- Provera okruženja

PRIPREMA MODELA

- Nakon što je izvršena provera izvoza modela, sledeći korak je pre-processing, kao priprema grafa za kvantizaciju:
 1. Dobijanje oblika svakog tenzora u grafu (ONNX shape inference). Omogućava pouzdanije korišćenje kasnijih alata.
 2. Optimizacija modela: Prepisivanje originalnog grafa, fuzija potrebnih čvorova, tako da se npr. dve operacije spoje u jedan čvor sa izmenjenim težinama.
- Zatim se razmatraju tipovi kvantizacije i oni koji će biti korišćeni za ovaj slučaj.

TIPOVI KVANTIZACIJE

- Podela po tome kada se kvantizacija odvija:
 - PTQ (Post training quantization) ←
 - QAT (Quantization aware training)
- Podela po tretmanu aktivacija:
 - Dinamička
 - Statička ← Preporuka autora za CNN
- Podela po tome šta se kvantizuje:
 - Parametri (težine i biasi) ←
 - Parametri (težine i biasi) i aktivacije ←
- Podela po šemi mapiranja:
 - Simetrična ← Za težine
 - Asimetrična ← Za aktivacije
- Po granularnosti:
 - Po tenzoru ← Za aktivacije, uvek
 - Po kanalu ← Za težine
- Po preciznosti:
 - INT16, INT8, INT4, INT2 ←
 - Praktično Teorijski

← Zadato u zadatku

← ONNX preporuka

← Za slučaj kvantizacije aktivacija

POSTUPAK KVANTIZACIJE

ONNX RUNTIME FUNKCIJA

- Kvantizacija se može izvoditi u dve varijante, u zavisnosti od toga šta se kvantizuje
 - Samo parametri (težine i biasi): ručna izmena grafa
 - Parametri i aktivacije: pozivom funkcije `quantize_static()`

A) Samo parametri (težine i biasi)

ONNX Runtime nema gotovu funkciju za ovaj slučaj: `quantize_static()` uvek kvantizuje i aktivacije, a `quantize_dynamic()` podrazumevano daje drugačiji format i preporučen je za RNN/transformere, a ne za CNN.

Parametri se kvantizuju (per-channel, simetrično, zero point = 0), a u graf se umeću `DequantizeLinear` čvorovi koji ih pri izvršavanju vraćaju u FP32.

B) Parametri i aktivacije


Parametri aktivacija računaju se unapred, na kalibracionom skupu.

- Kvantizacija zahteva $\text{opset} \geq 10$ (per-channel ≥ 13), a 16-bitni Q/DQ tipovi vezani su za opset 21.

POSTUPAK KVANTIZACIJE

ISHOD

- Nakon postupka kvantizacije dobija se novi model mreže, kao graf, sada izmenjen.
- Struktura originalnih operatora se zadržava, tj. ne prepravlja se sama mreža.
- U graf se umeću dodatni čvorovi koji vrednosti prevode između FP32 i niže preciznosti.
- *QuantizeLinear* pakuje FP32 u celobrojni zapis, a *DequantizeLinear* ga vraća u FP32 pre ulaska u operator.



- Runtime stapa QDQ parove sa operatorom u celobrojni kernel.

POSTUPAK KVANTIZACIJE

POREĐENJE

- Na kraju postupka, dobijeni su sledeći modeli:
 - Originalni model mreže, FP32
 - Kvantizovani model, INT16
 - Kvantizovani model, INT8
- Ovi modeli se porede preko tri testa:
 - Tačnost: isti test skup kroz sve modele i merenje metrika (top 1 tačnost, matrica konfuzije).
 - Memorija: poređenje veličine fajla modela.
 - Brzina zaključivanja: trajanje inferencije na istom skupu ulaza. Nekoliko "zagrevajućih" prolaza pre merenja (prvi prolaz je uvek sporiji zbog inicijalizacije), pa onda prosek preko više ponavljanja.

POSTUPAK KVANTIZACIJE

DODATNI KORAK, PO POTREBI

- Ukoliko tačnost neprihvatljivo padne nakon postupka kvantizacije, postoji i naredni korak, debugovanje.
- Ideja debugovanja je poređenje težina (i/ili aktivacija), tenzor po tenzor, sa originalnim modelom i pronalazak mesta gde se najviše razlikuju.
- Težine su statične, pa se porede direktno.
- Aktivacije zavise od ulaza, pa se moraju uhvatiti tokom izvršavanja. Ima tri koraka, koja se rade za oba modela (preuredi se model da čuva međurezultate, propuste se podaci, pa se upare vrednosti oba modela).
- Tako su dobijeni tenzori koji najviše odstupaju.
- Za takve tenzore postoje dve opcije:
 - Isključiti ih iz kvantizacije, tj. ostaviti u originalnom zapisu, to je tzv. mešovita kvantizacija.
 - Promeniti metod kvantizacije za te tenzore.
- Nakon primene ovih koraka, ponovo se proverava tačnost.

NIŽE BITSKE PRECIZNOSTI

- ONNX format definiše i niže preciznosti (INT4, INT2), ali se ONNX Runtime u praksi oslanja na 8-bitnu kvantizaciju.
- 4-bit podrška postoji, ali je ograničena: samo težine (ne i aktivacije) i samo pojedine operacije. Konvolucija nije među njima, pa za CNN mreže nije direktno primenljiva.
- 2-bit nije podržan kao gotov put, već samo kao tip u formatu.
- Za niže preciznosti realan pristup je kvantizacija van ONNX-a, pa naknadni izvoz modela.
- Kroz projekat će ovo biti detaljnije i konkretnije razrađeno, uz širi osvrt na to kakve benefite 4-bit i 2-bit preciznosti donose (dodatno smanjenje memorije i ubrzanje) i pod kojim uslovima se isplate.

KORIŠĆENI IZVORI

Specifikacija ONNX formata:

- QuantizeLinear operator: https://onnx.ai/onnx/operators/onnx__QuantizeLinear.html
- DequantizeLinear operator: https://onnx.ai/onnx/operators/onnx__DequantizeLinear.html
- Formule za scale i zero point: https://onnx.ai/onnx/operators/onnx__DynamicQuantizeLinear.html
- ONNX IR specifikacija (struktura grafa, tipovi podataka):
<https://github.com/onnx/onnx/blob/main/docs/IR.md>
- 4-bitni celobrojni tipovi u ONNX formatu: <https://onnx.ai/onnx/technical/int4.html>

ONNX Runtime dokumentacija:

- <https://onnxruntime.ai/docs/performance/model-optimizations/quantization.html>

Ostalo:

- Arhitektura CNN: Y. LeCun i dr., "Gradient-Based Learning Applied to Document Recognition", Proc. IEEE, 1998.
- MNIST dataset: <https://docs.pytorch.org/vision/stable/generated/torchvision.datasets.MNIST.html>
- Izvoz PyTorch modela u ONNX: <https://pytorch.org/docs/stable/onnx.html>
- Netron (vizuelizacija grafa): <https://netron.app>

HVALA NA PAŽNJI!